




Ensemble Híbrido: A Refinaria de Dados

Clusterização de clientes e descoberta de regras de associação para ações cirúrgicas de CRM na plataforma Prestador Nota 10.

O Ecossistema PN10: Um Marketplace Bilateral


Demanda - Aplicativo do Cliente



Foco: Jornada fluida, previsível e sem atrito (Passwordless, empilhamento de serviços/carrinho).

Dinâmica: Parametrização exata de itens, precificação transparente e geolocalização.


Oferta - Aplicativo do Prestador



Foco: Rigor de conformidade e construção de autoridade (KYC em 5 etapas).

Dinâmica: Documentoscopia, Prova de Vida, Radar de Oportunidades e Carteira Digital.

O Desafio da Mineração Global Indiscriminada



Diluição Estatística


Clientes de contratação única aumentam o denominador da base sem contribuir com cestas correlacionadas, esmagando o Suporte de padrões reais.

Regras Espúrias

Serviços de alta frequência marginal geram métricas de Confiança artificiais pelo mero acaso, resultando em um Lift inútil (próximo a 1,0).

Analisar a base transacional inteira de uma só vez não gera inteligência; gera ruído estatístico.

A Solução: Pipeline de Ensemble Híbrido



A segmentação prévia atua como um filtro inteligente que preserva a densidade transacional dos clientes valiosos.


Fundamento Dimensional e Integração

Camadas da Arquitetura

 **OLTP (pn10):** Espelho relacional da API.

 **DW (dw):** Esquema Estrela com fatos atômicos.

 **Datamarts (dm_*):** Agregações para BI.




A Ponte de Integração

O output da clusterização Python é gravado fisicamente na dimensão **dw.dim_cliente_segmento**, desacoplando o ML do BI e permitindo análises fluídas via SQL/Metabase.

Estágio 1: Segmentação com K-Means e Silhueta

Curva de Inércia (Cotovelo)



Silhouette Score



Engenharia de Features (9 Dimensões)

- Qtd. Pedidos
- Valor Médio
- Taxa de Cancelamento
- Recência (dias)
- Diversidade de Categorias

Insight Box

O Coeficiente de Silhueta atingiu seu pico ótimo de 0.217 com $k=2$, indicando a separabilidade global máxima entre a população de alto engajamento e a massa de usuários inativos.

Perfilamento de Clientes: O Contraste RFM

Cluster 0: Inativos / Baixo Engajamento

Volume:

154

clientes (55,6%)

Frequência:

1,80

pedidos

Ticket Médio:

R\$ 475,32

Recência:

813 dias

Taxa Cancelamento:

19,0%

Cluster 1: Clientes Fiéis / Alto Valor

Volume:

123

clientes (44,4%)

Frequência:

4,25

pedidos

Ticket Médio:

R\$ 542,24

Recência:

395 dias


Taxa Cancelamento:

16,0%

Estágio 2: Preparação para FP-Growth (Rollup Dimensional)

O Problema da Dispersão

Aplicar FP-Growth sobre 130 subcategorias finas geraria um suporte estatístico nulo, tornando impossível encontrar padrões frequentes.




A Solução do Rollup

Ao agregar para 25 Macro Categorias, modelamos a cesta de compras ao longo de todo o ciclo de vida do cliente com densidade suficiente.

Conclusão:

Esta agregação garante a significância estatística necessária para extrair dependências reais.

Padrões de Alto Valor (Segmento Fiéis)



Insight: Regras extraídas com suporte mínimo de 8% e limiar de Lift > 1,10. O agrupamento revelou cestas transacionais altamente acionáveis.

A Prova do Ensemble: O Valor da Segmentação

Fiéis (123 Clientes)



8 regras de alta dependência identificadas.
Densidade transacional isolada e preservada.


Inativos (154 Clientes)



Suporte reduzido até 2% resultando em Zero regras
identificadas. Cestas unitárias com recência média de 813 dias.

Conclusão: A mineração global indiscriminada teria diluído a regra 'Chaveiros → Hidráulica' para abaixo do limiar de significância. O agrupamento atua como um escudo protetor contra falsos positivos.

Módulo Preditivo: Ensemble Supervisionado para Churn



Gradient Boosting (Vencedor)	ROC-AUC: 0,583 Acurácia: 79,50%
Stacking Classifier	ROC-AUC: 0,577
Voting Classifier	ROC-AUC: 0,572
Random Forest	ROC-AUC: 0,533

Contexto: Expandindo a filosofia de ensemble sobre dados do DW. O teto de ROC-AUC reflete a origem sintética dos dados, atestando a ausência de overfitting.

A Anatomia do Cancelamento (Feature Importance)



Feature	Importance (%)
Valor do orçamento	22,24%
Avaliação do prestador	12,30%
Dias para primeiro orçamento	7,37%
Qtd. orçamentos recebidos	4,39%

22,24% | Valor do orçamento

Sensibilidade direta ao preço cobrado.

12,30% | Avaliação do prestador

Reputação prévia afeta a conversão final.

7,37% | Dias para primeiro orçamento

A agilidade no tempo de resposta é vital.

4,39% | Qtd. orçamentos recebidos

Concorrência e poder de escolha na plataforma.

O cancelamento não é aleatório; ele é impulsionado por atritos de preço e demora no atendimento.

Matriz de Ação Estratégica de CRM

Clientes Fiéis / Alto Valor

Padrão Descoberto

Alta afinidade transacional (Lift 1,390).

Ação 1: Cross-Sell Inteligente

Sugerir agendamento hidráulico durante o checkout de um serviço de chaveiro.

Ação 2: Bundling

Criar combos 'Manutenção Residencial Total' com desconto.

Inativos / Baixo Engajamento

Padrão Descoberto

Compras isoladas e alta recência (813 dias).

Ação 1: Contenção

Evitar ofertas agressivas de cross-sell precoce devido ao alto risco de rejeição.

Ação 2: Reativação

Disparo de cupom focado em atrito zero com validade curta (15 dias).

Transparência e Rigor Científico




Esparsidade Transacional

Base realística de 800 pedidos (2,9 p/cliente). Os lifts encontrados validam o pipeline analítico, mas requerem maior volume para leis definitivas.




Origem Sintética

O teto preditivo (ROC-AUC 0,583) reflete dados gerados sem causalidade determinística de churn, comprovando a total ausência de overfitting artificial.



Silhouette Moderado

O escore de 0,217 reflete a ausência de uma regra de segmentação intencional embutida na geração dos dados originais.



Perda por Rollup

A necessária agregação macroestatística dilui as especificidades técnicas originais, como a distinção fina entre instalação e manutenção térmica.

Entregáveis e Próximos Passos

Reprodutibilidade 100%

- ✓ **Orquestração:** Scripts .sh e .ps1 para pipeline automatizado ponta a ponta.
- ✓ **Integração:** Cargas SQL e views (vw_segmentacao_clientes) prontas para BI.
- ✓ **Transparência:** Código modularizado em Python (Scikit-learn, MLxtend).

Roadmap Técnico

