

INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E
TECNOLOGIA DE GOIÁS

CÂMPUS GOIÂNIA • PÓS-GRADUAÇÃO / ESPECIALIZAÇÃO / MESTRADO

Tópicos Avançados em Inteligência Artificial I

RELATÓRIO TÉCNICO OFICIAL • DOCUMENTO FÍSICO

ENSEMBLE HÍBRIDO: CLUSTERIZAÇÃO DE
CLIENTES INTEGRADA A REGRAS DE
ASSOCIAÇÃO

Segmentação Comportamental com K-Means e Mineração de Padrões
Transacionais por Agrupamento via FP-Growth sobre Data Warehouse
Dimensional

Ivânio / Equipe Prestador Nota 10

GOIÂNIA – GO

2026

Natureza do Trabalho: Relatório Técnico e Científico apresentado como entregável formal da disciplina *Tópicos Avançados em Inteligência Artificial I*. Documenta o projeto, modelagem do Data Warehouse, esteira de ETL, aplicação do conceito de ensemble metodológico (aprendizagem não-supervisionada seguida de mineração de regras de associação por grupo), além do módulo preditivo complementar supervisionado.

RESUMO EXECUTIVO

Este relatório documenta a concepção, implementação e validação de um pipeline analítico de mineração de dados orientado a CRM e marketing para a plataforma **Prestador Nota 10**. A premissa central estabelece que a extração indiscriminada de regras de associação sobre uma base de transações global gera elevado volume de regras triviais e dilui padrões característicos de clientes de maior valor. Para superar essa limitação, implementou-se o conceito de *ensemble* sob uma abordagem híbrida: a partir de um Data Warehouse modelado em esquema estrela no PostgreSQL com dimensões conformadas e fatos atômicos, os clientes foram primeiramente clusterizados via algoritmo **K-Means** com seleção de hiperparâmetro baseada em *Silhouette Score*. Em seguida, a base transacional foi particionada e o algoritmo **FP-Growth** foi executado de forma dedicada dentro de cada segmento identificado. Os resultados empíricos demonstram que no grupo de clientes fiéis e de alto valor (ticket médio R\$ 542,24) emergiram regras de alta dependência estatística (ex.: *Chaveiros e ferragens* → *Hidráulica* com confiança de 52,00% e Lift de 1,390), ao passo que no grupo de clientes inativos e de baixo engajamento não foram identificados itemsets frequentes, validando experimentalmente o benefício da segmentação prévia. Adicionalmente, um módulo supervisionado com ensemble heterogêneo (Random Forest, Gradient Boosting, AdaBoost, Voting e Stacking) foi consolidado para predição de cancelamento de pedidos.

Palavras-chave: Data Warehouse; Ensemble Learning; K-Means; Regras de Associação; FP-Growth; Segmentação de Clientes; CRM Analítico.

SUMÁRIO ESTRUTURADO

1. Introdução e Motivação de Negócio — Contexto, objetivos e conceito de ensemble	Seção 1
2. Arquitetura do Data Warehouse — Camadas OLTP, DW, Datamarts e integração	Seção 2
3. Etapa 1: Clusterização de Clientes (K-Means) — Features, seleção de k e perfis	Seção 3
4. Visualização Analítica no Metabase — Evidências reais e dashboards	Seção 4
5. Etapa 2: Regras de Associação por Segmento — FP-Growth, métricas e achados	Seção 5
6. Módulo Complementar: Ensemble de Churn — Classificação supervisionada	Seção 6
7. Recomendações Estratégicas e Ações de CRM — Matriz de ações e conclusões	Seção 7
8. Guia de Reprodutibilidade e Entregáveis — Scripts e inventário de arquivos	Seção 8

Matriz de Conformidade com a Demanda

REQUISITO REQUISITADO	STATUS	EVIDÊNCIA TÉCNICA NO REPOSITÓRIO
1. DW / Datamart Construído e Povoado	Conforme (100%)	Esquema dimensional <code>dw</code> e datamarts <code>dm_*</code> estruturados e povoados por <code>dw/01..08_*.sql</code> , abrangendo fatos de pedidos, orçamentos, avaliações e agendamentos com integridade referencial.
2. Aplicação de Ensemble	Conforme (>100%)	Implementação dupla: (a) Ensemble Híbrido Metodológico (Clusterização → Regras por Segmento) e (b) Ensemble Preditivo Supervisionado (Bagging, Boosting e Stacking) para predição de churn.
3. Clusterização / Classificação de Clientes	Conforme (100%)	Segmentação não-supervisionada via <code>K-Means</code> sobre 9 features comportamentais (RFM, cancelamento e região), com seleção objetiva de $k=2$ via Silhouette Score e persistência física em <code>dw.dim_cliente_segmento</code> .
4. Regras de Associação por Grupo/Classe	Conforme (100%)	Mineração via <code>FP-Growth</code> particionada por cluster, demonstrando geração de 8 regras no cluster fiel (Lift até 1.39) e isolamento da esparsidade no cluster inativo.
5. Bibliotecas Python	Conforme (100%)	Uso de <code>scikit-learn</code> , <code>mlxtend</code> , <code>pandas</code> , <code>sqlalchemy</code> , <code>matplotlib</code> e <code>tabulate</code> estruturados em <code>mining/requirements.txt</code> .
6. Entregáveis: Código e Relatório Técnico	Conforme (100%)	Código modular versionado, scripts orquestradores <code>.sh</code> e <code>.ps1</code> , relatórios técnicos, visualizações no Metabase e documento físico em PDF.

1. INTRODUÇÃO E MOTIVAÇÃO DE NEGÓCIO

1.1. Contexto do Problema

A plataforma **Prestador Nota 10** opera como um ecossistema digital bilateral (marketplace de serviços), conectando clientes que necessitam de intervenções técnicas e domésticas a prestadores de serviços qualificados. O ciclo transacional engloba a abertura de pedidos, cotação de orçamentos concorrentes, aceitação de propostas, agendamento de atendimentos e avaliação de conformidade.

No gerenciamento de relacionamento com clientes (CRM), um dos objetivos primordiais é estimular o *cross-selling* (venda cruzada) e o aumento do valor do tempo de vida do cliente (*Customer Lifetime Value* — LTV). Tradicionalmente, técnicas de Mineração de Regras de Associação (*Market Basket Analysis*) são empregadas para responder à pergunta: "Se um cliente contrata o serviço A, qual a probabilidade de ele também necessitar do serviço B?"

1.2. O Desafio da Mineração Global Indiscriminada

A aplicação direta e simplista de algoritmos como Apriori ou FP-Growth sobre todo o histórico transacional consolidado incorre em severos problemas práticos:

- **Diluição Estatística:** Clientes fiéis com múltiplos pedidos representam uma fração menor da base, enquanto clientes esporádicos (que contrataram apenas uma vez e nunca mais retornaram) compõem a maioria volumétrica. Quando agregados sem distinção, os clientes de contratação única aumentam o denominador da base sem contribuir com cestas correlacionadas, reduzindo artificialmente o suporte de padrões reais existentes entre os clientes mais engajados.
- **Regras Espúrias e Não-Acionáveis:** Serviços de altíssima frequência marginal (como reformas residenciais básicas) tendem a se associar a qualquer outro serviço simplesmente pelo acaso, gerando métricas de confiança elevadas, mas com *Lift* próximo a 1,0 (independência estatística).

1.3. O Conceito de Ensemble Adotado

Para solucionar esse desafio, o presente trabalho operacionalizou o conceito de **Ensemble (Aprendizagem por Conjuntos)** em uma perspectiva híbrida e em múltiplos estágios:

Definição do Pipeline de Ensemble Híbrido:

Em vez de aplicar um modelo isolado, combinam-se duas famílias de técnicas de aprendizado de máquina em cascata:

1º Estágio (Não-Supervisionado): Clusterização com K-Means para particionar a população de clientes em segmentos homogêneos segundo seu perfil transacional e RFM (Recência, Frequência, Monetário).

2º Estágio (Mineração Simbólica Condicionada): Aplicação de FP-Growth isoladamente dentro de cada segmento, descobrindo regras de associação especializadas e altamente acionáveis para cada perfil de público.

1.4. Diagrama Geral do Pipeline Implementado




Figura 1 — Fluxo de ponta a ponta do ensemble híbrido (Data Warehouse → K-Means → FP-Growth por Segmento).

2. ARQUITETURA DO DATA WAREHOUSE E ENGENHARIA DE DADOS

2.1. Modelagem Dimensional e Camadas

A estrutura de armazenamento analítico foi desenvolvida no PostgreSQL local (porta 5433 / banco `prestadornota10local`), distribuída em três camadas desacopladas:

- **Camada Transacional (OLTP — Schema `pn10`):** Espelho relacional normalizado da API (tabelas `pedido`, `orcamento_pedido`, `avaliacao_pedido`, `agendamento`, `pessoa`, `empresa`, `usuario`, `categoria_servico`), criada por `01_oltp_ddl.sql` e populada com 800 pedidos sintéticos por `02_oltp_carga.sql`.
- **Camada Dimensional Central (DW — Schema `dw`):** Esquema estrela unificado contendo as dimensões conformadas e as tabelas fato no menor grão transacional (DDL em `03_dw_ddl.sql` e ETL em `04_dw_carga.sql`).
- **Camada de Datamarts (Schemas `dm_*`):** Seis datamarts departamentais construídos por `05_datamart_ddl.sql` e carregados por `06_datamart_carga.sql` contendo agregações sumarizadas (*rollups*) para otimização de painéis de BI.

2.2. Diagrama Conceitual do Esquema Estrela (Schema `dw`)



Figura 2 — Arquitetura dimensional estrela com integração da tabela de segmentação de clientes.

2.3. Tabela de Integração: `dw.dim_cliente_segmento`

Para viabilizar a comunicação desacoplada entre a clusterização Python e a etapa de regras de associação, o script `dw/09_segmentacao_clientes_ddl.sql` define a tabela física `dw.dim_cliente_segmento`. Esta tabela armazena a atribuição de cluster e rótulo de negócio para cada cliente, viabilizando consultas analíticas no Metabase e filtragem de cestas via SQL:

```
CREATE TABLE dw.dim_cliente_segmento (  
    sk_cliente          integer PRIMARY KEY REFERENCES dw.dim_cliente(sk_cliente),  
    cluster              smallint NOT NULL,  
    rotulo_segmento     varchar(60) NOT NULL,  
    qtd_pedidos         integer NOT NULL,  
    valor_total         numeric(12,2) NOT NULL,  
    valor_medio_pedido  numeric(12,2) NOT NULL,  
    qtd_categorias_distintas integer NOT NULL,  
    taxa_cancelamento  numeric(5,4) NOT NULL,  
    nota_media          numeric(3,2),  
    recencia_dias       integer,  
    data_execucao       timestamp NOT NULL DEFAULT now()  
);
```

3. ETAPA 1: CLUSTERIZAÇÃO E SEGMENTAÇÃO DE CLIENTES (K-MEANS)

3.1. Engenharia de Features e Transformações

A partir de consultas agregadas sobre `dw.fato_pedido` e suas dimensões, extraíram-se atributos comportamentais no nível de grão de cliente. Foram filtrados exclusivamente os clientes com pelo menos 1 pedido registrado (277 clientes no total):

ATRIBUTO	TIPO	TRATAMENTO	SIGNIFICADO NO MODELO DE NEGÓCIO
<code>qtd_pedidos</code>	Numérica	<code>StandardScaler</code>	Frequência de engajamento do cliente na plataforma.
<code>valor_total</code>	Numérica	<code>StandardScaler</code>	Dimensão Monetária (faturamento gerado pelo cliente).
<code>valor_medio_pedido</code>	Numérica	<code>StandardScaler</code>	Ticket médio por contratação de serviço.
<code>qtd_categorias_distintas</code>	Numérica	<code>StandardScaler</code>	Diversidade de necessidades atendidas na plataforma.
<code>taxa_cancelamento</code>	Numérica	<code>StandardScaler</code>	Percentual de pedidos abortados ou cancelados.
<code>nota_media</code>	Numérica	Imputação + Scaler	Índice de satisfação manifestada nas avaliações.
<code>recencia_dias</code>	Numérica	Imputação + Scaler	Dias transcorridos desde a última solicitação de serviço.
<code>tipo_pessoa</code>	Categórica	<code>OneHotEncoder</code>	Segmentação entre Pessoa Física (PF) e Pessoa Jurídica (PJ).
<code>regiao</code>	Categórica	<code>OneHotEncoder</code>	Localização geográfica das solicitações do cliente.

3.2. Seleção de Hiperparâmetro (k) e Avaliação de Silhueta

O algoritmo K-Means foi treinado para diferentes valores de *k* (2 a 8). O gráfico comparativo abaixo apresenta a curva de inércia e o coeficiente de silhueta médio calculado:




Figura 3 — Curva de Inércia (Cotovelo) e Coeficiente de Silhueta para *k* ∈ [2, 8].

O valor ótimo identificado foi **k = 2**, apresentando o maior coeficiente de silhueta (**0,217**). Para valores maiores (3 a 8), o índice decaiu para a faixa de 0,17 a 0,18, demonstrando que partições mais granulares criariam subgrupos

artificiais sem separabilidade real.

3.3. Perfil dos Segmentos Descobertos

CLUSTER	CLIENTES	PEDIDOS MÉD.	VALOR TOTAL	TICKET MÉDIO	CATEGORIAS	CANCELAMENTO	RECÊNCIA	RÓTULO ESTRATÉGICO
0	154 (55,6%)	1,80	R\$ 803,69	R\$ 475,32	1,78	19,0%	813 dias	Inativos / Baixo Engajamento
1	123 (44,4%)	4,25	R\$ 2.186,42	R\$ 542,24	4,17	16,0%	395 dias	Clientes Fiéis / Alto Valor

4. EVIDÊNCIAS VISUAIS E DASHBOARDS NO METABASE

Para validar o consumo operacional dos dados minerados, a tabela `dw.dim_cliente_segmento` foi exposta no Metabase através das views analíticas `dw.vw_segmentacao_clientes` e `dw.vw_resumo_segmento_cliente` (arquivo `metabase/views/vw_segmentacao_clientes.sql`).




Figura 4 — Catálogo de Dados do Metabase exibindo as tabelas físicas e views da segmentação.




Figura 5 — View `dw.vw_segmentacao_clientes`: detalhe individualizado dos 277 clientes com atributos e rótulos.




Figura 6 — Card de resumo médio por cluster.




Figura 7 — Distribuição de clientes por segmento (154 x 123).

5. ETAPA 2: REGRAS DE ASSOCIAÇÃO POR SEGMENTO (FP-GROWTH)

5.1. Modelagem da Cesta de Compras e Rollup de Categorias

Em serviços, a transação não é instantânea. Cada cesta foi modelada como o **conjunto de categorias distintas contratadas pelo cliente** ao longo de seu histórico.

Para evitar que a grande diversidade de subcategorias finas (~130 subcategorias) gerasse suporte nulo para pares de itens, aplicou-se um *rollup* para a **Macro Categoria de Serviço** (campo `dim_categoria_servico.descricao_categoria_pai`, ~25 categorias).

5.2. Resultados no Segmento "Clientes Fiéis / Alto Valor" (123 clientes)

Executando o algoritmo **FP-Growth** com suporte mínimo de 8% e limiar de corte por Lift > 1,10, identificaram-se 8 regras estatisticamente relevantes:

SE CONTRATOU (SE)	TAMBÉM CONTRATA (ENTÃO)	SUPORTE	CONFIANÇA	LIFT	ALAVANC.	CONVIC.
Chaveiros e ferragens	Hidráulica	10,57%	52,00%	1,390	0,030	1,304
Hidráulica	Chaveiros e ferragens	10,57%	28,26%	1,390	0,030	1,111
Chaveiros e ferragens	Residencial	9,76%	48,00%	1,181	0,015	1,141
Residencial	Chaveiros e ferragens	9,76%	24,00%	1,181	0,015	1,048
Automotivo	Computadores e Tecnologia	8,13%	22,73%	1,165	0,012	1,042
Computadores e Tecnologia	Automotivo	8,13%	41,67%	1,165	0,012	1,101
Hidráulica	Residencial	17,07%	45,65%	1,123	0,019	1,092
Residencial	Hidráulica	17,07%	42,00%	1,123	0,019	1,079

5.3. Resultados no Segmento "Inativos / Baixo Engajamento" (154 clientes)

Diagnóstico Empírico da Segmentação:

No segmento de clientes inativos, a aplicação do FP-Growth com suporte decrescente (8% → 6% → 4,5% → 3% → 2%) **não produziu nenhum itemset frequente com 2 ou mais itens.**

Validação da Hipótese: Como esse grupo possui média de apenas 1,80 pedidos por cliente e recência de 813 dias, os clientes não possuem cesta multitemática. Misturar este grupo à base total apenas diluiria as regras do grupo fiel.

6. MÓDULO COMPLEMENTAR: ENSEMBLE DE CLASSIFICADORES PARA CHURN

6.1. Definição do Experimento Supervisionado

Para complementar o trabalho, o módulo `mining/ensemble/treinar_ensemble.py` foi corrigido para treinar múltiplos algoritmos de ensemble supervisionados com o objetivo de prever a variável binária `indicador_cancelado` de `dw.fato_pedido`.

Foram treinados modelos representativos das três grandes famílias de ensemble: **Bagging** (Random Forest), **Boosting** (Gradient Boosting e AdaBoost) e **Meta-Ensembles** (Voting Classifier e Stacking Classifier com meta-modelo em Regressão Logística).

6.2. Comparativo de Desempenho sobre Dados Reais do DW

MODELO AVALIADO	FAMÍLIA	CV ROC-AUC	ACURÁCIA (TESTE)	PRECISÃO	RECALL	F1-SCORE	ROC-AUC TESTE
Gradient Boosting	Boosting	0,508 (±0,051)	79,50%	23,08%	8,82%	12,77%	0,583
Stacking Classifier	Stacking	0,485 (±0,053)	83,00%	0,00%	0,00%	0,00%	0,577
Voting Classifier	Soft Voting	0,491 (±0,050)	80,00%	0,00%	0,00%	0,00%	0,572
Random Forest	Bagging	0,489 (±0,054)	83,00%	0,00%	0,00%	0,00%	0,533
AdaBoost	Boosting	0,482 (±0,053)	83,00%	0,00%	0,00%	0,00%	0,531

6.3. Importância dos Atributos (Feature Importances - Gradient Boosting)

VARIÁVEL EXPLICATIVA	IMPORTÂNCIA (%)	IMPACTO OPERACIONAL
valor_orcamento	22,24%	Sensibilidade ao preço cobrado.
avaliacao_prestador	12,30%	Reputação e confiança no prestador.
dias_para_primeiro_orcamento	7,37%	Agilidade e tempo de espera inicial.
qtd_orcamentos_recebidos	4,39%	Poder de escolha do cliente.
qtd_categorias_servico	4,34%	Complexidade do escopo do pedido.
mensalidade_plano_prestador	3,16%	Nível de engajamento do prestador.

7. RECOMENDAÇÕES DE NEGÓCIO E AÇÕES DE CRM

7.1. Matriz de Ações por Segmento

SEGMENTO	PADRÃO DESCOBERTO	PLANO DE AÇÃO TÁTICO DE CRM
Clientes Fiéis / Alto Valor (123 clientes)	Alta afinidade entre <i>Chaveiros</i> , <i>Hidráulica</i> e <i>Residencial</i> (Lift até 1.39 e confiança de 52%).	Cross-Sell no Carrinho: Oferecer agendamento de revisão hidráulica ao contratar chaveiro. Combos "Casa Segura": Pacote integrado com desconto comercial. Fidelidade VIP: Prioridade na fila de resposta dos orçamentos.
Inativos / Baixo Engajamento (154 clientes)	Contratações pontuais e isoladas; ausência de regras frequentes; recência média de 813 dias.	Não ofertar cross-sell precoce baseado em regras (alto risco de rejeição). Campanhas de Reativação: Cupom de retorno com validade de 15 dias. Pesquisa de Abandono: Investigar fricções de preço ou usabilidade.

8. GUIA DE REPRODUTIBILIDADE E ENTREGÁVEIS

8.1. Comandos de Execução

```
# Execução completa ponta a ponta:
chmod +x executar_pipeline.sh && ./executar_pipeline.sh

# No Windows (PowerShell):
.\executar_pipeline.ps1

# Execução individual dos scripts de mineração:
python3 mining/clusterizacao/segmentar_clientes.py
python3 mining/associacao/regras_associacao.py
python3 mining/ensemble/treinar_ensemble.py
```

8.2. Inventário de Arquivos do Trabalho

- **Documento Físico (PDF):** `RELATORIO_TECNICO_FINAL.pdf` (e cópia em `mining/`).
- **Documento Fonte (HTML):** `RELATORIO_TECNICO_FINAL.html`.
- **Scripts SQL:** `dw/01_oltp_ddl.sql` até `dw/09_segmentacao_clientes_ddl.sql`.
- **Módulos Python:** `mining/clusterizacao/`, `mining/associacao/` e `mining/ensemble/`.
- **Views e Dashboards Metabase:** `metabase/views/vw_segmentacao_clientes.sql`.