

INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DE GOIÁS

DISCIPLINA: TÓPICOS AVANÇADOS EM INTELIGÊNCIA ARTIFICIAL I

ENSEMBLE HÍBRIDO: CLUSTERIZAÇÃO DE CLIENTES INTEGRADA A REGRAS DE ASSOCIAÇÃO

**Segmentação Comportamental com K-Means e Mineração de Padrões Transacionais por
Agrupamento via FP-Growth sobre Data Warehouse Dimensional**

Professor: Doutor Sirlon Diniz de Carvalho

Alunos: Robson Pereira da Silva e Ivânio José da Rocha Júnior

Goiânia – GO

2026

Sumário

Resumo Executivo	4
Sumário Estruturado do Relatório	5
Matriz de Conformidade com os Requisitos da Disciplina	6
1. Introdução e Motivação de Negócio.....	8
1.1. Contexto do Problema	8
1.2. Descrição da Aplicação.....	8
1.2.1 Aplicativo do Cliente (`pn10-cliente`)	9
1.2.1.1 Onboarding e Autenticação.....	9
1.2.1.2 Parametrização e Quantificação do Serviço	9
1.2.1.3 Agendamento, Endereço, Fotos e Empilhamento	9
1.2.1.4 Módulo de Endereçamento e Geolocalização	10
1.2.1.5 Ciclo de Vida e Acompanhamento de Pedidos	10
1.2.2 Aplicativo do Prestador (`pn10-prestador`).....	11
1.2.2.1 Onboarding Rigoroso e Compliance (KYC — *Know Your Customer*)	11
1.2.2.2 Verificação de Identidade e Prova de Vida	12
1.2.2.3 Arquitetura de Navegação	12
1.2.2.4 Gestão Operacional de Ordens de Serviço	12
1.2.2.5 Módulo Financeiro e Carteira Digital.....	13
1.2.2.6 Perfil Profissional, Reputação e Gamificação.....	13
1.3. O Desafio da Mineração Global Indiscriminada	13
2. Arquitetura do Data Warehouse e Engenharia de Dados.....	14
2.1. Modelagem Dimensional e Camadas.....	14
2.2. Diagrama Conceitual do Esquema Estrela (Schema dw)	15
2.3. Tabela de Integração: dw.dim_cliente_segmento.....	15
3. Etapa 1: Clusterização e Segmentação de Clientes (K-Means).....	15
3.1. Engenharia de Features e Transformações	15
3.2. Seleção de Hiperparâmetro (k) e Avaliação de Silhueta	17
3.3. Perfil dos Segmentos Descobertos	18
4. Evidências Visuais e Dashboards no Metabase	18
5. Etapa 2: Regras de Associação por Segmento (FP-Growth).....	21
5.1. Modelagem da Cesta de Compras e Rollup de Categorias	21
5.2. Resultados no Segmento 'Clientes Fiéis / Alto Valor' (123 clientes).....	21
5.3. Resultados no Segmento 'Inativos / Baixo Engajamento' (154 clientes).....	22
5.4. Valor da Abordagem Ensemble vs. Mineração Global Indiscriminada	22

6. Módulo Complementar: Ensemble de Classificadores para Churn	22
6.1. Definição do Experimento Supervisionado	22
6.2. Comparativo de Desempenho sobre Dados Reais do DW	23
6.3. Importância dos Atributos (Feature Importances - Gradient Boosting).....	23
7. Limitações Metodológicas e Riscos Técnicos (Transparência Científica)	24
8. Correções Técnicas Realizadas no Repositório	24
9. Recomendações Estratégicas de Negócio e Ações de CRM.....	25
9.1. Matriz de Ações por Segmento de Cliente.....	25
9.2. Próximos Passos Técnicos.....	25
10. Guia de Reprodutibilidade e Entregáveis.....	26
10.1. Comandos de Execução do Pipeline.....	26
10.2. Inventário de Arquivos do Projeto	26

Resumo Executivo

Este relatório documenta a concepção, implementação e validação de um pipeline analítico de mineração de dados orientado a CRM e marketing para a plataforma Prestador Nota 10.

A premissa central estabelece que a extração indiscriminada de regras de associação sobre uma base de transações global gera elevado volume de regras triviais e dilui padrões característicos de clientes de maior valor.

Para superar essa limitação, implementou-se o conceito de ensemble sob uma abordagem híbrida: a partir de um Data Warehouse modelado em esquema estrela no PostgreSQL com dimensões conformadas e fatos atômicos, os clientes foram primeiramente clusterizados via algoritmo K-Means com seleção de hiperparâmetro baseada em Silhouette Score.

Em seguida, a base transacional foi particionada e o algoritmo FP-Growth foi executado de forma dedicada dentro de cada segmento identificado. Os resultados empíricos demonstram que no grupo de clientes fiéis e de alto valor (ticket médio R\$ 542,24) emergiram regras de alta dependência estatística (ex.: Chaveiros e ferragens → Hidráulica com confiança de 52,00% e Lift de 1,390), ao passo que no grupo de clientes inativos e de baixo engajamento não foram identificados itemsets frequentes, validando experimentalmente o benefício da segmentação prévia.

Adicionalmente, um módulo supervisionado com ensemble heterogêneo (Random Forest, Gradient Boosting, AdaBoost, Voting e Stacking) foi consolidado para predição de cancelamento de pedidos.

Palavras-chave: Data Warehouse; Ensemble Learning; K-Means; Regras de Associação; FP-Growth; Segmentação de Clientes; CRM Analítico.

Sumário Estruturado do Relatório

- **Seção 1** — Introdução e Motivação de Negócio — Contexto, objetivos e conceito de ensemble
- **Seção 2** — Arquitetura do Data Warehouse — Camadas OLTP, DW, Datamarts e integração
- **Seção 3** — Etapa 1: Clusterização de Clientes (K-Means) — Features, seleção de k e perfis
- **Seção 4** — Evidências Visuais no Metabase — Catálogo de dados, views e dashboards
- **Seção 5** — Etapa 2: Regras de Associação por Segmento — FP-Growth, métricas e achados
- **Seção 6** — Módulo Complementar: Ensemble de Churn — Classificação supervisionada
- **Seção 7** — Limitações Metodológicas e Riscos Técnicos — Transparência científica
- **Seção 8** — Correções Técnicas Realizadas no Repositório — Histórico de engenharia
- **Seção 9** — Recomendações Estratégicas e Ações de CRM — Matriz de ações táticas
- **Seção 10** — Guia de Reprodutibilidade e Entregáveis — Scripts e inventário de arquivos

Matriz de Conformidade com os Requisitos da Disciplina

Requisito do Enunciado	Status	Evidência Técnica no Repositório
1. DW / Datamart Construído e Povoado	Conforme (100%)	Esquema dimensional dw e datamarts dm_* estruturados e povoados por dw/01..08_*.sql, abrangendo fatos de pedidos, orçamentos, avaliações e agendamentos com integridade referencial.
2. Aplicação de Ensemble	Conforme (>100%)	Implementação dupla: (a) Ensemble Híbrido Metodológico (Clusterização → Regras por Segmento) e (b) Ensemble Preditivo Supervisionado (Bagging, Boosting e Stacking) para predição de churn.
3. Clusterização / Classificação de Clientes	Conforme (100%)	Segmentação não-supervisionada via K-Means sobre 9 features comportamentais (RFM, cancelamento e região), com seleção objetiva de k=2 via Silhouette Score e persistência física em dw.dim_cliente_segmento.
4. Regras de Associação por Grupo/Classe	Conforme (100%)	Mineração via FP-Growth particionada por cluster, demonstrando geração de 8 regras no cluster fiel (Lift até 1.39) e isolamento da esparsidade no cluster inativo.

Requisito do Enunciado	Status	Evidência Técnica no Repositório
5. Bibliotecas Python Especializadas	Conforme (100%)	Uso de scikit-learn, mlxtend, pandas, sqlalchemy, matplotlib e tabulate estruturados em mining/requirements.txt.
6. Entregáveis: Código e Relatório Técnico	Conforme (100%)	Código modular versionado, scripts orquestradores .sh e .ps1, relatórios técnicos, visualizações no Metabase, PDF oficial e documento Word editável.

1. Introdução e Motivação de Negócio

1.1. Contexto do Problema

A plataforma **Prestador Nota 10 (PN10)** é um ecossistema digital bilateral (*two-sided on-demand marketplace*) desenvolvido para conectar **clientes** (consumidores finais e empresas) que necessitam de serviços de reparo, instalação, manutenção e assistência técnica a **prestadores de serviços autônomos e microempresas qualificadas**.

No gerenciamento de relacionamento com clientes (CRM), um dos objetivos primordiais é estimular o cross-selling (venda cruzada) e o aumento do valor do tempo de vida do cliente (Customer Lifetime Value — LTV).

Tradicionalmente, técnicas de Mineração de Regras de Associação (Market Basket Analysis) são empregadas para responder à pergunta: 'Se um cliente contrata o serviço A, qual a probabilidade de ele também necessitar do serviço B?'

1.2. Descrição da Aplicação

Concebida com foco na transparência e eliminação da assimetria de informações típica do setor de serviços operacionais, a plataforma atua com **tabelamento de serviços com preço fixo** para tarefas padronizadas e **orçamentos personalizados** para intervenções sob medida. Regionalmente, a base operacional concentra-se no estado de Goiás (Grande Goiânia e microrregião de DDD 62), alimentando diretamente a base analítica do repositório **pn10-data-warehouse**.

O ecossistema é formado por dois aplicativos móveis distintos e integrados:

1.2.1 PN10 Cliente (pn10-cliente): interface voltada à busca, contratação parametrizada, agendamento, geolocalização e acompanhamento de chamados.

1.2.2. PN10 Prestador (pn10-prestador): interface de trabalho do profissional para gestão de ordens de serviço (OS), precificação por especialidade, comprovação de conformidade (KYC), carteira digital e reputação.

O aplicativo do cliente foi projetado para oferecer uma jornada de contratação fluida, previsível e sem atrito, dividindo a experiência em etapas claras e objetivas.

1.2.1 Aplicativo do Cliente (`pn10-cliente`)

1.2.1.1 Onboarding e Autenticação

- **Tela de Abertura (*Splash Screen*)**: apresentação da identidade visual da marca PN10, com paleta centrada no azul institucional e vermelho para ações prioritárias (*Call-to-Action*).
- **Autenticação Descomplicada (*Passwordless* via SMS/OTP)**: acesso rápido informando o número de telefone celular, com recebimento de código numérico de validação temporário (OTP - *One-Time Password*) e fluxo de reenvio/recuperação.
- **Cadastro e Privacidade**: formulário enxuto de dados pessoais e adesão explícita às políticas de privacidade e proteção de dados (LGPD).
- **Prévia de Esforço e Custo**: cada serviço expõe logo no cartão o **tempo médio estimado de execução** (ex.: *Tempo médio: 2 hora(s)*) e o **preço de partida tabelado** (ex.: *R\$ 135,60**).
- **Opção de Fuga — "Orçamento Personalizado"**: caso a necessidade do cliente seja específica ou envolva variáveis complexas não contempladas no catálogo padrão, um botão de destaque abre o fluxo de orçamento livre, permitindo descrever o problema e anexar fotos antes da precificação pelo profissional.

1.2.1.2 Parametrização e Quantificação do Serviço

- **Seleção Detalhada de Itens**: o cliente seleciona a variante exata do serviço a ser prestado (ex.: *Caixa de gordura até 60 litros, Caixa de gordura de 60 a 100 litros*).
- **Controles Incrementais (+ / -)**: seletores numéricos para definir quantidades de itens ou pontos de atendimento, com atualização em tempo real do subtotal acumulado.

1.2.1.3 Agendamento, Endereço, Fotos e Empilhamento

- **Tipo de Atendimento**:
 - **Agora**: chamada emergencial para atendimento imediato pelo prestador disponível mais próximo.
 - **Para o dia**: agendamento programado com seleção de data no calendário e faixa de horário.
- **Endereço da Ocorrência**: vinculação do local exato da execução.
- **Inclusão de Mídia e Descrição Qualitativa**:
 - Upload de fotos do local/problema através da câmera do celular ou da galeria de fotos.
 - Inclusão de observações textuais e instruções específicas para orientar previamente o prestador de serviços.
- **Empilhamento de Serviços (*Service Bundling* / Carrinho)**:

- Mecânica central da plataforma que permite adicionar outros serviços complementares na mesma visita técnica (ex.: *Dedetização R\$ 135,60* somada a *Instalação de Chuveiro R\$ 100,00*).
- O sistema consolida automaticamente o **Tempo Total Estimado** (ex.: *3 horas*) e o **Valor Total do Pedido** (ex.: *R\$ 235,60*).
- **Finalização:** escolha da modalidade de pagamento, revisão dos valores e confirmação com botão de cancelamento imediato caso necessário.

1.2.1.4 Módulo de Endereçamento e Geolocalização

- **Localização Instantânea:** funcionalidade de detecção via GPS do aparelho ("*Usar localização atual*").
- **Mapeamento com Duplo Marcador (*Pin*):** interface de mapa que distingue com precisão a posição física momentânea do cliente ("*Onde você está*") do ponto de atendimento técnico ("*Onde será o serviço*").
- **Tipologia do Imóvel e Detalhamento:** especificação estrutural da residência (*Casa, Apartamento, Prédio Comercial*), inclusão de número, complemento, bloco e pontos de referência.
- **Endereços Favoritos:** atalhos para seleção rápida de endereços habituais cadastrados ("*Casa*", "*Trabalho*").

1.2.1.5 Ciclo de Vida e Acompanhamento de Pedidos

Painel segmentado em abas com indicadores cromáticos de estado:

- **Abertos (Laranja):** chamados emitidos aguardando triagem ou aceite do prestador no raio geográfico.
- **Confirmados (Azul):** prestador alocado, em rota de deslocamento ou com data/horário confirmados.
- **Finalizados (Verde):** ordens executadas, com emissão de recibo e abertura da tela de avaliação e gorjeta.
- **Cancelados (Vermelho):** solicitações descontinuadas pelo cliente ou por ausência de prestadores aptos.

Solicitação de serviços com preço fixo (CLIENTE)



1.2.2 Aplicativo do Prestador (`pn10-prestador`)

O aplicativo do prestador foi concebido como um painel operacional completo para o profissional de campo, priorizando rigor de conformidade, clareza sobre faturamento e construção de autoridade profissional.

1.2.2.1 Onboarding Rigoroso e Compliance (KYC — *Know Your Customer*)

O cadastro do prestador passa por uma esteira de aprovação estruturada em **5 etapas consecutivas**:

Etapa 1 — Dados Pessoais: nome civil completo, CPF, RG, órgão expedidor, data de nascimento, filiação materna (nome da mãe), e-mail e telefone de contato.

Etapa 2 — Dados Comerciais e Experiência: razão social, nome fantasia, enquadramento fiscal (MEI/CNPJ ou autônomo individual) e tempo de atuação profissional no setor.

Etapa 3 — Habilidades e Precificação Personalizada: seleção de especialidades técnicas (ex.: *Encanador, Eletricista, Climatização, Pintura*) e ativação individual dos subserviços realizados, permitindo ao prestador parametrizar seus próprios valores tabelados e estimativas de duração.

Etapa 4 — Dados Bancários e Chave Pix: inclusão de instituição financeira (banco, agência, conta corrente ou poupança) e chave Pix para viabilizar os repasses automáticos de remuneração.

Etapa 5 — Termos Contratuais e Validação SMS: assinatura digital dos termos de uso da plataforma, cláusulas de responsabilidade técnica, LGPD e validação do chip telefônico via token SMS.

1.2.2.2 Verificação de Identidade e Prova de Vida

- **Documentoscopia Digital:** captura de imagens nítidas da CNH ou RG oficial (frente e verso), analisadas para prevenir fraudes cadastrais.
- **Prova de Vida (Biometria Facial):** captura de selfie em tempo real validando a presença física do requerente contra os documentos anexados, conferindo máxima segurança aos clientes que recebem o técnico em domicílio.

1.2.2.3 Arquitetura de Navegação

Estruturada em 3 seções centrais:

- **Pedidos:** quadro de novas solicitações disponíveis e serviços em andamento.
- **Financeiro:** controle de ganhos diários/mensais, saldos e histórico de transferências.
- **Perfil:** currículo público, selos de qualidade e dados cadastrais.

1.2.2.4 Gestão Operacional de Ordens de Serviço

- **Radar de Oportunidades:** notificação e visualização de chamados abertos nas imediações geográficas do prestador, contendo:
 - Distância e endereço aproximado;
 - Valor líquido da remuneração;
 - Fotos da anomalia anexadas pelo cliente;
 - Descrição detalhada do escopo do reparo.
- **Transição de Status Operacional:** fluxo simples de avanço da ordem: "*Aceitar Chamado*" → "*A Caminho*" → "*Iniciar Execução*" → "*Concluir Serviço*".

1.2.2.5 Módulo Financeiro e Carteira Digital

- **Painel de Faturamento:** consolidação transparente de entradas brutas e receitas líquidas diárias, semanais e mensais.
- **Saldo Disponível para Saque:** valor líquido liberado para transferência bancária imediata via Pix.
- **Extrato Detalhado de Transações:** histórico discriminado por ordem de serviço, demonstrando valor pago pelo cliente, retenção da taxa de intermediação da plataforma (*take rate*) e valor creditado na carteira.

1.2.2.6 Perfil Profissional, Reputação e Gamificação

- **Perfil Público do Prestador:** página visualizada pelos clientes antes e durante a contratação, exibindo foto profissional, nome, tempo de histórico na plataforma e total de serviços realizados.
- **Score de Avaliação:** média quantitativa ponderada de 1 a 5 estrelas (ex.: **4.7 ★** baseada em avaliações reais de clientes).
- **Selos de Elogios (*Badges* de Reconhecimento):** medalhas qualitativas concedidas ao final dos serviços, incentivando o padrão de atendimento:
 -  *Bom papo* (cortesia e boa comunicação)
 -  *Ótimo serviço* (qualidade técnica e acabamento)
 -  *Muito rápido* (eficiência de execução)
 -  *Pontual* (cumprimento estrito do horário agendado)

1.3. O Desafio da Mineração Global Indiscriminada

A aplicação direta e simplista de algoritmos como Apriori ou FP-Growth sobre todo o histórico transacional consolidado incorre em severos problemas práticos identificados na literatura de Data Mining:

- **Diluição Estatística:** Clientes fiéis com múltiplos pedidos representam uma fração menor da base, enquanto clientes esporádicos (que contrataram apenas uma vez e nunca mais retornaram) compõem a maioria volumétrica. Quando agregados sem distinção, os clientes de contratação única aumentam o denominador da base sem contribuir com cestas correlacionadas, reduzindo artificialmente o suporte de padrões reais existentes entre os clientes mais engajados.
- **Regras Espúrias e Não-Acionáveis:** Serviços de altíssima frequência marginal (como reparos residenciais básicos) tendem a se associar a qualquer outro serviço simplesmente pelo acaso, gerando métricas de confiança elevadas, mas com Lift próximo a 1,0 (independência estatística entre antecedentes e consequentes).

1.4. O Conceito de Ensemble Adotado

Em vez de aplicar um modelo isolado, combinam-se duas famílias de técnicas de aprendizado de máquina em cascata:

1º Estágio (Não-Supervisionado): Clusterização com K-Means para particionar a população de clientes em segmentos homogêneos segundo seu perfil transacional e RFM (Recência, Frequência, Monetário).

2º Estágio (Mineração Simbólica Condicionada): Aplicação de FP-Growth isoladamente dentro de cada segmento, descobrindo regras de associação especializadas e altamente acionáveis para cada perfil de público.

1.5. Diagrama Geral do Pipeline Implementado



Figura 1 — Fluxo de ponta a ponta do ensemble híbrido (Data Warehouse → Feature Engineering → K-Means → Tabela Intermediária → FP-Growth por Segmento).

2. Arquitetura do Data Warehouse e Engenharia de Dados

2.1. Modelagem Dimensional e Camadas

A estrutura de armazenamento analítico foi desenvolvida no PostgreSQL local (porta 5433 / banco prestadornota10local), distribuída em três camadas desacopladas:

- **Camada Transacional (OLTP — Schema pn10):** Espelho relacional normalizado da API (tabelas pedido, orcamento_pedido, avaliacao_pedido, agendamento, pessoa, empresa, usuario, categoria_servico), criada por 01_oltp_ddl.sql e populada com 800 pedidos sintéticos por 02_oltp_carga.sql.
- **Camada Dimensional Central (DW — Schema dw):** Esquema estrela unificado contendo as dimensões conformadas e as tabelas fato no menor grão transacional (DDL em 03_dw_ddl.sql e ETL em 04_dw_carga.sql).
- **Camada de Datamarts (Schemas dm_*):** Seis datamarts departamentais construídos por 05_datamart_ddl.sql e carregados por 06_datamart_carga.sql contendo agregações sumarizadas (rollups) para otimização de painéis analíticos.

2.2. Diagrama Conceitual do Esquema Estrela (Schema dw)



Figura 2 — Arquitetura dimensional estrela com integração da tabela de segmentação de clientes *dw.dim_cliente_segmento*.

2.3. Tabela de Integração: *dw.dim_cliente_segmento*

Para viabilizar a comunicação desacoplada entre a clusterização Python e a etapa de regras de associação, o script `dw/09_segmentacao_clientes_ddl.sql` define a tabela física *dw.dim_cliente_segmento*. Esta tabela armazena a atribuição de cluster e rótulo de negócio para cada cliente, viabilizando consultas analíticas no Metabase e filtragem de cestas via SQL:

```
CREATE TABLE dw.dim_cliente_segmento (  
    sk_cliente          integer PRIMARY KEY REFERENCES  
dw.dim_cliente(sk_cliente),  
    cluster             smallint NOT NULL,  
    rotulo_segmento     varchar(60) NOT NULL,  
    qtd_pedidos         integer NOT NULL,  
    valor_total         numeric(12,2) NOT NULL,  
    valor_medio_pedido  numeric(12,2) NOT NULL,  
    qtd_categorias_distintas integer NOT NULL,  
    taxa_cancelamento  numeric(5,4) NOT NULL,  
    nota_media          numeric(3,2),  
    recencia_dias       integer,  
    data_execucao       timestamp NOT NULL DEFAULT now()  
);
```

3. Etapa 1: Clusterização e Segmentação de Clientes (K-Means)

3.1. Engenharia de Features e Transformações

A partir de consultas agregadas sobre *dw.fato_pedido* e suas dimensões conformadas, extraíram-se atributos comportamentais no nível de grão de cliente. Foram filtrados

exclusivamente os clientes com pelo menos 1 pedido registrado (277 dos 300 clientes cadastrados), visto que clientes sem pedido não possuem cesta transacional:

Atributo	Tipo	Tratamento	Significado no Modelo de Negócio
qtd_pedidos	Numérica	StandardScaler	Frequência de engajamento do cliente na plataforma.
valor_total	Numérica	StandardScaler	Dimensão Monetária (faturamento gerado pelo cliente).
valor_medio_pedido	Numérica	StandardScaler	Ticket médio por contratação de serviço.
qtd_categorias_distintas	Numérica	StandardScaler	Diversidade de necessidades atendidas na plataforma.
taxa_cancelamento	Numérica	StandardScaler	Percentual de pedidos abortados ou cancelados.
nota_media	Numérica	Imputação + Scaler	Índice de satisfação manifestada nas avaliações.
recencia_dias	Numérica	Imputação + Scaler	Dias transcorridos desde a última solicitação de serviço.
tipo_pessoa	Categórica	OneHotEncoder	Segmentação entre Pessoa Física (PF) e Jurídica (PJ).
regiao	Categórica	OneHotEncoder	Localização geográfica das solicitações do cliente.

3.2. Seleção de Hiperparâmetro (k) e Avaliação de Silhueta

O algoritmo K-Means foi treinado para diferentes valores de k (variando de 2 a 8). O gráfico comparativo abaixo apresenta a curva de inércia e o coeficiente de silhueta médio calculado para cada partição:




Figura 3 — Curva de Inércia (Cotovelo) e Coeficiente de Silhueta para $k \in [2, 8]$.

Valor de k	Inércia (Within-Cluster Sum of Squares)	Silhouette Score Médio	Interpretação
2	1625.07	0.217 (ÓTIMO ESCOLHIDO)	Maior separabilidade global entre engajados e inativos.
3	1424.65	0.170	Decaimento acentuado da coesão interna dos clusters.
4	1273.95	0.176	Partição intermediária sem ganho explicativo.
5	1127.95	0.181	Subsegmentos menores e fragmentados.
6	1026.39	0.187	Sobreposição acentuada de perfis transacionais.
7	942.05	0.184	Instabilidade estatística nas partições.

Valor de k	Inércia (Within-Cluster Sum of Squares)	Silhouette Score Médio	Interpretação
8	895.50	0.171	Hiperfragmentação da base de clientes.

3.3. Perfil dos Segmentos Descobertos

A segmentação resultou em dois agrupamentos comportamentais nitidamente contrastantes:

Cluster	Clientes	Pedidos Méd.	Valor Total	Ticket Médio	Categorias	Cancelamento	Recência	Rótulo Estratégico
0	154 (55,6%)	1,80	R\$ 803,69	R\$ 475,32	1,78	19,0%	813 dias	Inativos / Baixo Engajamento
1	123 (44,4%)	4,25	R\$ 2.186,42	R\$ 542,24	4,17	16,0%	395 dias	Clientes Fiéis / Alto Valor

4. Evidências Visuais e Dashboards no Metabase

Para comprovar a operacionalização da segmentação em ferramentas de Business Intelligence, a tabela `dw.dim_cliente_segmento` foi exposta no Metabase através de duas views SQL criadas pelo script `metabase/views/vw_segmentacao_clientes.sql`: `dw.vw_segmentacao_clientes` (detalhe por cliente) e `dw.vw_resumo_segmento_cliente` (perfil médio por cluster).




Figura 4 — Catálogo de Dados do Metabase exibindo as tabelas físicas do schema dw e as views analíticas de segmentação.

Sk Cliente	Codigo Cliente	Nome	Tipo Pessoa	Nome Cidade	UF	Regiao	Cluster	Rotulo Segm
274	274	João Castro	PF	Salete	SC	Sul	0	Inativos / Baixo Engajamento
166	166	Lucas Campos	PF	São Miguel do Tapuio	PI	Nordeste	0	Inativos / Baixo Engajamento
96	96	Patrícia Freitas	PF	Cruz Machado	PR	Sul	0	Inativos / Baixo Engajamento
199	199	Diego Rocha	PF	Treze Tilias	SC	Sul	0	Inativos / Baixo Engajamento
291	291	Marcos Souza	PF	Itaitinga	CE	Nordeste	0	Inativos / Baixo Engajamento
236	236	Eduardo Nascimento	PF	Palmelo	GO	Centro-Oeste	0	Inativos / Baixo Engajamento
7	7	André Duarte	PF	Tanquinho	BA	Nordeste	0	Inativos / Baixo Engajamento
241	241	Gustavo Gomes	PF	Alexânia	GO	Centro-Oeste	0	Inativos / Baixo Engajamento
212	212	Márcio Costa	PF	Coluna	MG	Sudeste	0	Inativos / Baixo Engajamento
23	23	Thiago Duarte	PF	Sarapui	SP	Sudeste	0	Inativos / Baixo Engajamento
298	298	Leonardo Moreira	PF	Sumé	PB	Nordeste	0	Inativos / Baixo Engajamento
95	95	Diego Carvalho	PF	Nova Castilho	SP	Sudeste	0	Inativos / Baixo Engajamento
102	102	João Cavalcanti	PF	Claraval	MG	Sudeste	0	Inativos / Baixo Engajamento
73	73	Juliana Farias	PF	Jenipapo dos Vieiras	MA	Nordeste	0	Inativos / Baixo Engajamento
65	65	Pedro Souza	PF	Carpina	PE	Nordeste	0	Inativos / Baixo Engajamento
231	231	Rogério Cavalcanti	PF	Balneário Pinhal	RS	Sul	0	Inativos / Baixo Engajamento
284	284	Pedro Rodrigues	PF	Puxinanã	PB	Nordeste	0	Inativos / Baixo Engajamento
185	185	Obra Fácil 185	PJ	Jijoca de Jericoacoa...	CE	Nordeste	0	Inativos / Baixo Engajamento
164	164	Márcio Duarte	PF	Camocim	CE	Nordeste	0	Inativos / Baixo Engajamento

Figura 5 — View dw.vw_segmentacao_clientes: consulta com granularidade de cliente exibindo métricas RFM e rótulos de segmento atribuídos.




Figura 6 — Card analítico de resumo médio por cluster (pedidos médios, ticket médio, recência e faturamento acumulado).




Figura 7 — Gráfico de contagem de clientes por segmento gerado no Metabase (154 Inativos vs 123 Clientes Fiéis).

5. Etapa 2: Regras de Associação por Segmento (FP-Growth)

5.1. Modelagem da Cesta de Compras e Rollup de Categorias

Em um marketplace de serviços, as contratações ocorrem ao longo do tempo. Dessa forma, a cesta de compras de cada cliente foi modelada como o conjunto consolidado de categorias distintas que o cliente já contratou no histórico da plataforma.

Para evitar que a dispersão em ~130 subcategorias finas gerasse suporte nulo para pares de itens, aplicou-se um rollup dimensional para a Macro Categoria de Serviço (campo `dim_categoria_servico.descricao_categoria_pai`, contendo ~25 macro categorias). Essa agregação é fundamental para que as métricas estatísticas de frequência atinjam significância na base de clientes.

5.2. Resultados no Segmento 'Clientes Fiéis / Alto Valor' (123 clientes)

Executando o algoritmo FP-Growth com suporte mínimo de 8% e limiar de corte por Lift > 1,10, identificaram-se 8 regras de associação estatisticamente consistentes:

Se Contratou (SE)	Também Contrata (ENTÃO)	Suporte	Confiança	Lift	Alavancagem	Convicção
Chaveiros e ferragens	Hidráulica	10,57%	52,00%	1,390	0,030	1,304
Hidráulica	Chaveiros e ferragens	10,57%	28,26%	1,390	0,030	1,111
Chaveiros e ferragens	Residencial	9,76%	48,00%	1,181	0,015	1,141
Residencial	Chaveiros e ferragens	9,76%	24,00%	1,181	0,015	1,048
Automotivo	Computadores e Tecnologia	8,13%	22,73%	1,165	0,012	1,042
Computadores e Tecnologia	Automotivo	8,13%	41,67%	1,165	0,012	1,101

Se Contratou (SE)	Também Contrata (ENTÃO)	Suporte	Confiança	Lift	Alavancagem	Convicção
Hidráulica	Residencial	17,07%	45,65%	1,123	0,019	1,092
Residencial	Hidráulica	17,07%	42,00%	1,123	0,019	1,079

5.3. Resultados no Segmento 'Inativos / Baixo Engajamento' (154 clientes)

No segmento de clientes inativos, a aplicação do algoritmo FP-Growth com suporte decrescente (8% → 6% → 4,5% → 3% → 2%) não produziu nenhum itemset frequente com 2 ou mais itens.

Validação Experimental: Como este grupo possui média de apenas 1,80 pedidos por cliente e recência média de 813 dias, os clientes não possuem cestas multicategoria.

A ausência de regras confirma a hipótese metodológica: misturar esses clientes à base total apenas diluiria as regras do grupo fiel e geraria falsos positivos de independência estatística.

5.4. Valor da Abordagem Ensemble vs. Mineração Global Indiscriminada

Ao comparar os resultados obtidos com e sem segmentação, constata-se a eficácia do ensemble metodológico: na mineração global sem clusterização, a regra 'Chaveiros e ferragens → Hidráulica' tem seu suporte diluído abaixo do limiar de corte estatístico devido ao grande volume de clientes inativos com apenas 1 pedido. O agrupamento prévio atua como um filtro inteligente que preserva a densidade transacional dos clientes valiosos.

6. Módulo Complementar: Ensemble de Classificadores para Churn

6.1. Definição do Experimento Supervisionado

Para consolidar a visão de ensemble sob todas as suas manifestações, o módulo mining/ensemble/treinar_ensemble.py foi mantido e corrigido para treinar classificadores supervisionados para predição da variável binária indicador_cancelado em dw.fato_pedido.

Foram avaliadas as três principais famílias de ensemble: Bagging (Random Forest), Boosting (Gradient Boosting e AdaBoost) e Meta-Ensembles (Voting e Stacking Classifier com meta-modelo em Regressão Logística).

6.2. Comparativo de Desempenho sobre Dados Reais do DW

Modelo Avaliado	Família	CV ROC-AUC	Acurácia (Teste)	Precisão	Recall	F1-Score	ROC-AUC Teste
Gradient Boosting	Boosting	0,508 (±0,051)	79,50%	23,08%	8,82%	12,77%	0,583 (Melhor)
Stacking Classifier	Stacking	0,485 (±0,053)	83,00%	0,00%	0,00%	0,00%	0,577
Voting Classifier	Soft Voting	0,491 (±0,050)	80,00%	0,00%	0,00%	0,00%	0,572
Random Forest	Bagging	0,489 (±0,054)	83,00%	0,00%	0,00%	0,00%	0,533
AdaBoost	Boosting	0,482 (±0,053)	83,00%	0,00%	0,00%	0,00%	0,531

6.3. Importância dos Atributos (Feature Importances - Gradient Boosting)

Variável Explicativa	Importância Relativa (%)	Impacto Operacional
valor_orcamento	22,24%	Sensibilidade ao preço cobrado pelo prestador.
avaliacao_prestador	12,30%	Reputação e nível de confiança no profissional.
dias_para_primeiro_orcamento	7,37%	Agilidade na resposta inicial ao pedido.
qtd_orcamentos_recebidos	4,39%	Poder de escolha e concorrência na solicitação.
qtd_categorias_servico	4,34%	Complexidade e diversidade do escopo do serviço.
mensalidade_plano_prestador	3,16%	Nível de engajamento do prestador na plataforma.

7. Limitações Metodológicas e Riscos Técnicos (Transparência Científica)

Em conformidade com as boas práticas de experimentação e rigor científico, documentam-se as restrições e riscos associados ao experimento:

- **Esparsidade da Base Transacional:** A base possui 800 pedidos distribuídos entre 277 clientes ativos (~2,9 pedidos por cliente). Para Market Basket Analysis clássico, trata-se de uma base com esparsidade moderada. Os valores de Lift encontrados (máximo 1,390) devem ser interpretados como prova de conceito do pipeline metodológico e não como verdades definitivas de negócio.
- **Silhouette Score Moderado (0,217):** O score máximo de silhueta obtido (0,217 para $k=2$) é baixo em termos absolutos (valores $> 0,5$ indicam forte densidade e separação). Isso decorre diretamente do fato de os dados do DW serem sintéticos, sem uma regra deliberada de segmentação embutida na geração inicial.
- **Origem Sintética dos Dados:** Como os dados foram gerados programaticamente sem relações causais determinísticas de cancelamento, os modelos preditivos supervisionados operaram próximos ao baseline aleatório (ROC-AUC 0,583), comprovando que o pipeline lê os dados reais do DW sem artificialismos.
- **Rollup Dimensional de Categorias:** Embora necessário para gerar suporte estatístico, o agrupamento em macro categorias perde detalhes específicos (ex.: não distingue instalação de manutenção dentro de Climatização).

8. Correções Técnicas Realizadas no Repositório

Durante a evolução do projeto e consolidação desta branch, foram realizadas correções críticas de engenharia de software:

- **Correção do Dialeto SQLAlchemy:** A connection string `postgresql://` (sem driver explícito) fazia o SQLAlchemy 2.1 tentar o dialeto `psycopg (v3)` em vez de `psycopg2` (instalado), caindo silenciosamente no gerador sintético embutido sem tocar no banco de dados real. Corrigido especificando `postgresql+psycopg2://`.
- **Ambiente Python e Dependências:** Padronização das dependências no arquivo `mining/requirements.txt` e criação do ambiente virtual `mining/.venv` devidamente documentado no `.gitignore`.
- **Resolução de Caminhos Relativos:** Ajuste da orquestração para execução a partir da raiz do repositório, evitando a criação de diretórios aninhados como `mining/mining/`.

9. Recomendações Estratégicas de Negócio e Ações de CRM

9.1. Matriz de Ações por Segmento de Cliente

Segmento de Clientes	Padrão Transacional Descoberto	Plano de Ação Tático de CRM
Clientes Fiéis / Alto Valor (123 clientes)	Alta afinidade transacional entre Chaveiros, Hidráulica e Residencial (Lift até 1,390 e confiança de 52,00%).	1. Cross-Sell Inteligente: Sugerir agendamento hidráulico durante o checkout de chaveiro. 2. Pacotes Combinados: Criar combos 'Manutenção Residencial Total' com desconto. 3. Fidelização: Canal prioritário de suporte e benefícios de pontuação.
Inativos / Baixo Engajamento (154 clientes)	Contratações pontuais e isoladas; ausência de regras frequentes; recência média elevada (813 dias).	1. Evitar ofertas agressivas de cross-sell precoce (alto risco de rejeição). 2. Campanhas de Reativação: Cupom de desconto com validade de 15 dias para segunda contratação. 3. Pesquisas de Churn: Questionários rápidos para mapear atritos de preço e atendimento.

9.2. Próximos Passos Técnicos

- Aumentar a densidade de pedidos por cliente nos scripts de carga sintética para reduzir a esparsidade transacional.
- Reavaliar o valor de k à medida que novos dados reais forem integrados ao Data Warehouse.
- Revisar as features explicativas de cancelamento para identificar métricas de maior poder preditivo.

10. Guia de Reprodutibilidade e Entregáveis

10.1. Comandos de Execução do Pipeline

```
# Execução completa ponta a ponta (Linux / macOS):  
chmod +x executar_pipeline.sh && ./executar_pipeline.sh  
  
# Execução no Windows (PowerShell):  
.\executar_pipeline.ps1  
  
# Execução individual das etapas de mineração (a partir da raiz):  
python3 mining/clusterizacao/segmentar_clientes.py  
python3 mining/associacao/regras_associacao.py  
python3 mining/ensemble/treinar_ensemble.py
```

10.2. Inventário de Arquivos do Projeto

- **Documento Word (.docx):** RELATORIO_TECNICO_FINAL.docx (no root e em mining/) — Relatório oficial em Word totalmente editável.
- **Documento PDF (.pdf):** RELATORIO_TECNICO_FINAL.pdf (no root e em mining/) — Versão final impressa com diagramação ABNT.
- **Documentos Fonte:** RELATORIO_TECNICO_FINAL.html e RELATORIO_TECNICO.md — Fontes originais em Markdown e HTML.
- **Scripts de Banco (SQL):** dw/01_oltp_ddl.sql até dw/09_segmentacao_clientes_ddl.sql — DDL e cargas do Data Warehouse.
- **Scripts de Mineração:** mining/clusterizacao/, mining/associacao/ e mining/ensemble/ — Códigos de mineração e aprendizado.
- **Views de BI:** metabase/views/vw_segmentacao_clientes.sql — Views analíticas para dashboards no Metabase.